

Automates et Langages

Partie 2

Emmanuelle Grislin



INSA 3 FISE et FISA Informatique

Partie 2

Mars 2021

Navigation icons: back, forward, search, etc.

Emmanuelle Grislin (INSA-UPHF)

Automates et Langages

Mars 2021

1 / 35

Objectifs du cours 2

► Savoirs :

- *connaissance de la hiérarchie de Chomsky*
- *connaissance du théorème de Kleene*
- *connaître les opérations sur les langages qui conservent et celles qui ne conservent pas la propriété de type "algébrique"*

► Savoir-faire :

- *établir si un mot m appartient à un langage L de type 3*
- *donner le langage reconnu par une grammaire de 3*
- *donner une grammaire engendrant un langage de type 3*
- *reconnaître le type d'un langage (principes)*
- *montrer qu'un langage est algébrique en utilisant les opérations sur les langages*

Navigation icons: back, forward, search, etc.

Emmanuelle Grislin (INSA-UPHF)

Automates et Langages

Mars 2021

2 / 35

Appartenance d'un mot à un langage

Problème

Un langage L étant fixé, comment savoir si un mot donné appartient à L ?

Une solution

Décrire une grammaire engendrant L qui va permettre :

- ▶ de produire tous les mots de L
- ▶ de savoir si un mot donné appartient à L

Difficulté

Complexité de la grammaire ?

Il existe différents "niveaux de complexité" de langage, et donc des grammaires engendrant ces langages : voir section suivante.

Hierarchie de Chomsky

Noam Chomsky (années 50) :

- ▶ complexité d'une grammaire // complexité des algorithmes associés
- ▶ complexité d'une grammaire // forme des règles de production
- ▶ classification des grammaires formelles en 4 types :
 - type 3 \subset type 2 \subset type 1 \subset type 0
 - le type 3 est le plus simple




Figure – Types de grammaires

Un langage L est de type i ssi
il existe une grammaire G
de type i et telle que

$$L = L(G)$$

Grammaire de type 3 : régulière

Grammaire régulière (ou "rationnelle")

Grammaire définie par un quadruplet $G = \langle \Sigma, V, S, R \rangle$ avec

- ▶ Σ : ensemble fini de symboles terminaux
- ▶ V : ensemble fini de variables (symboles non terminaux, $\notin \Sigma$)
- ▶ S : symbole de V particulier appelé "axiome" ou "racine"
- ▶ R : ensemble fini de règles de production

Grammaire **régulière à droite** (*resp. à gauche*) :

toutes les règles sont de la forme :

$$X \rightarrow \omega Y \quad (\text{resp. } X \rightarrow Y\omega)$$

$$X \rightarrow \omega \quad \text{avec } X, Y \in V \text{ et } \omega \in \Sigma^*$$


- ▶ langages reconnus par les automates à états finis et les expressions régulières (vus en Partie 1)

Théorème de Kleene

Théorème de Kleene

Equivalence : $\mathcal{L}_{RecAFD} = \mathcal{L}_{ExpReg} = \mathcal{L}_{GramReg}$
avec

- ▶ \mathcal{L}_{RecAFD} la classe des langages reconnaissables par un automate fini
- ▶ \mathcal{L}_{ExpReg} la classe des langages qui peuvent être décrits par une expression régulière
- ▶ $\mathcal{L}_{GramReg}$ la classe des langages engendrés par une grammaire régulière



Transformation automate fini en grammaire

Pour tout automate fini $\mathcal{A} = \langle \Sigma \cup \{\epsilon\}, Q, q_0, F, \Delta \rangle$,
il existe une grammaire régulière à droite qui génère $L(\mathcal{A})$:

$G = \langle \Sigma, V, S, R \rangle$ avec

- ▶ $V = Q$ (ensemble des variables = ensemble des états),
- ▶ S = symbole de V associé à q_0 (axiome associé à l'état initial),
- ▶ $R = \{X \rightarrow \omega Y \mid (q_X, \omega, q_Y) \in \Delta\} \cup \{X \rightarrow \epsilon \mid X \in F\}$

Transformation grammaire régulière à droite en automate

Pour toute grammaire régulière à droite $G = \langle \Sigma, V, S, R \rangle$,
il existe un automate fini qui reconnaît $L(G)$:

$\mathcal{A} = \langle \Sigma \cup \{\epsilon\}, Q, q_0, F, \Delta \rangle$, avec

- ▶ Q : un état q_X pour chaque symbole X non terminal (de V),
- ▶ l'état initial q_0 correspond à l'axiome S ,
- ▶ F : états dont les non terminaux X de G ont une règle du type
 $X \rightarrow \epsilon$
- ▶ $\Delta = \{(q_X, \omega, q_Y) \mid \exists (X \rightarrow \omega Y) \in R\}$

Grammaire de type 2 : algébrique (ou "hors contexte" ou "non contextuelle")

Grammaire algébrique

- Règles de production de la forme :

$$T \rightarrow u$$

avec $T \in V$ et $u \in (\Sigma \cup V)^*$

- ▶ la partie gauche de la règle contient un unique non terminal

- ▶ le type de la plupart des langages de programmation

ex. :

- language C : http://www.cs.man.ac.uk/~pjj/bnf/c_syntax.bnf
- Prolog : http://cseweb.ucsd.edu/classes/fa09/cse130/misc/prolog/prolog_tutorial.pdf

- ▶ besoin d'automates à pile pour les reconnaître

- **détaillé dans la section suivante** du cours

Grammaire de type 1 : contextuelle

Grammaire contextuelle (ou "sensible au contexte")

- Règles de production de la forme :

$\alpha \rightarrow \beta$
avec α et $\beta \in (\Sigma \cup V)^*$ et $|\beta| \geq |\alpha|$

- ▶ partie gauche de la règle est non vide
- ▶ et partie droite contient plus de symboles que la gauche avec une exception pour $X \rightarrow \epsilon$

- ▶ toute grammaire de type 1 peut aussi s'écrire :

$$\gamma X \delta \rightarrow \gamma \beta \delta$$

avec $\gamma, \beta, \delta \in (\Sigma \cup V)^*$, $|\beta| \geq 1$, $X \in V$

- γ et δ sont appelés les **contextes** (gauche et droit) de la règle

Grammaire générale (ou "non contrainte")

- ▶ Règles de production de la forme :

$$\alpha \rightarrow \beta$$

avec α et $\beta \in (\Sigma \cup V)^*$

- ▶ Pas de contrainte sur les parties gauches et droites des règles.

Type d'un langage

Comment connaître le type d'un langage L ?

- ▶ si il existe une **expression régulière** ou un **automate** à états fini qui reconnaît L, alors
L est de type 3 (régulier) par le théorème d'équivalence de Kleen
- ▶ si il existe une grammaire G de type i qui engendre L,
alors L est au moins de type i (peut-être $> i$ si G est d'une complexité plus grande que nécessaire)
 - on regarde **la forme des règles** des grammaires qui l'engendrent :
existe-t-il une grammaire de type 3 ? sinon, de type 2 ? etc.
- ▶ par déduction en utilisant **les propriétés sur les langages** :
ex. :
 - l'union de 2 langages algébriques est un langage algébrique
 - le **lemme de l'Etoile** donne une condition que les mots d'un langage régulier doivent nécessairement satisfaire (Cf. cours Partie 1)

Comment connaître le type d'un langage L ?

- ▶ si il existe une **expression régulière** ou un **automate** à états fini qui reconnaît L , alors
 L est de type 3 (régulier) par le théorème d'équivalence de Kleen
- ▶ si il existe une grammaire G de type i qui engendre L , alors L est au moins de type i (peut-être $> i$ si G est d'une complexité plus grande que nécessaire)
 - on regarde **la forme des règles** des grammaires qui l'engendrent : existe-t-il une grammaire de type 3 ? sinon, de type 2 ? etc.
- ▶ par déduction en utilisant **les propriétés sur les langages** :

Union de langages algébriques

Soient les langages L_1 et L_2 deux langages algébriques sur l'alphabet Σ ,

Union :

- ▶ $L_1 \cup L_2 = \{u \in \Sigma^* \mid u \in L_1 \text{ ou } u \in L_2\}$
- ▶ l'union de 2 langages algébriques est algébrique

Démonstration :

- ▶ $L_1 = L(G_1)$ avec $G_1 = \langle \Sigma, V_1, S_1, R_1 \rangle$ et $L_2 = L(G_2)$ avec $G_2 = \langle \Sigma, V_2, S_2, R_2 \rangle$ où $V_1 \cap V_2 = \emptyset$ (ensembles de variables disjoints),
- ▶ soit S une nouvelle variable,
 $L_1 \cup L_2$ est engendré par la grammaire algébrique :
 $G = \langle \Sigma, V_1 \cup V_2 \cup \{S\}, S, R_1 \cup R_2 \cup \{S \rightarrow S_1 \mid S_2\} \rangle$
- ▶ la règle ajoutée est de la forme $T \rightarrow u$ avec $T \in V$ et $u \in (\Sigma \cup V)^*$

Union de langages algébriques

Exemple :

- ▶ $L = \{u \in \{a, b\}^* \mid u = a^n b^n \text{ ou } u = b^n a^n; n \geq 0\}$
- ▶ $L = \{u \in \{a, b\}^* \mid u = a^n b^n; n \geq 0\} \cup \{u \in \{a, b\}^* \mid u = b^n a^n; n \geq 0\}$
- ▶ $L_1 = L(G_1)$ avec $G_1 = \langle \{a, b\}, \{S_1\}, S_1, \{S_1 \rightarrow aS_1 b \mid \epsilon\} \rangle$
et $L_2 = L(G_2)$ avec $G_2 = \langle \{a, b\}, \{S_2\}, S_2, \{S_2 \rightarrow bS_2 a \mid \epsilon\} \rangle$
- ▶ L est engendré par la grammaire algébrique :
 $G = \langle \{a, b\}, \{S_1, S_2, S\}, S, R \rangle$ avec R :

$$\begin{array}{lcl} S & \rightarrow & S_1 \quad | \quad S_2 \\ S_1 & \rightarrow & aS_1 b \quad | \quad \epsilon \\ S_2 & \rightarrow & bS_2 a \quad | \quad \epsilon \end{array}$$

Produit de langages algébriques

Soient les langages L_1 et L_2 deux langages algébriques sur l'alphabet Σ ,

Produit :

- ▶ $L = L_1 L_2 = \{u \in \Sigma^* \mid \exists v_1 \in L_1 \text{ et } v_2 \in L_2, u = v_1 v_2\}$
- ▶ le produit de 2 langages algébriques est algébrique

Démonstration :

- ▶ $L_1 = L(G_1)$ avec $G_1 = \langle \Sigma, V_1, S_1, R_1 \rangle$ et $L_2 = L(G_2)$ avec $G_2 = \langle \Sigma, V_2, S_2, R_2 \rangle$ où $V_1 \cap V_2 = \emptyset$ (ensembles de variables disjoints),
- ▶ soit S une nouvelle variable,
 $L_1 L_2$ est engendré par la grammaire algébrique :
 $G = \langle \Sigma, V_1 \cup V_2 \cup \{S\}, S, R_1 \cup R_2 \cup \{S \rightarrow S_1 S_2\} \rangle$
- ▶ la règle ajoutée est de la forme $T \rightarrow u$ avec $T \in V$ et $u \in (\Sigma \cup V)^*$

Produit de langages algébriques

Exemple :

- ▶ $L = \{u \in \{a, b\}^* \mid u = a^n b^n b^p c^p; n \geq 0 \text{ et } p \geq 0\}$
- ▶ $L = L_1 L_2$ avec $L_1 = \{u \in \{a, b\}^* \mid u = a^n b^n; n \geq 0\}$ et $L_2 = \{u \in \{a, b\}^* \mid u = b^p c^p; p \geq 0\}$
- ▶ $L_1 = L(G_1)$ avec $G_1 = \langle \{a, b\}, \{S_1\}, S_1, \{S_1 \rightarrow aS_1b \mid \epsilon\} \rangle$
et $L_2 = L(G_2)$ avec $G_2 = \langle \{a, b\}, \{S_2\}, S_2, \{S_2 \rightarrow bS_2c \mid \epsilon\} \rangle$
- ▶ L est engendré par la grammaire algébrique :
 $G = \langle \{a, b\}, \{S_1, S_2, S\}, S, R \rangle$ avec R :

$$\begin{array}{lll} S & \rightarrow & S_1 S_2 \\ S_1 & \rightarrow & aS_1b \mid \epsilon \\ S_2 & \rightarrow & bS_2c \mid \epsilon \end{array}$$

Etoile de langages algébriques

Soit le langage algébrique L sur l'alphabet Σ ,

Etoile :

- ▶ $L^* = \bigcup_{n \geq 0} L^n = L^0 \cup L^1 \cup L^2 \cup \dots L^n$
- ▶ l'étoile d'un langage algébrique est algébrique

Démonstration :

- ▶ L^* est l'union de produits de langages algébriques \Rightarrow algébrique
- ▶ L engendré par $G = \langle \Sigma, V, S, R \rangle$
Soit S' une nouvelle variable,
 L^* est engendré par la grammaire algébrique :
 $G' = \langle \Sigma, V \cup \{S'\}, S', R \{S' \rightarrow S S' \mid \epsilon\} \rangle$
- ▶ la règle ajoutée est de la forme $T \rightarrow u$ avec $T \in V$ et $u \in (\Sigma \cup V)^*$

Etoile de langages algébriques

Exemple :

- ▶ Avec $L = \{u \in \{a, b\}^* \mid u = a^n b^n; n \geq 0\}$,
 - $L^0 = \emptyset, L^1 = L$
 - $L^2 = LL^1 = \{u \in \{a, b\}^* \mid u = a^n b^n a^p b^p; n \geq 0 \text{ et } p \geq 0\}$ algébrique car produit de 2 algébriques
 - $L^3 = LL^2 = \{u \in \{a, b\}^* \mid u = a^n b^n a^p b^p a^q b^q; n \geq 0, p \geq 0 \text{ et } q \geq 0\}$ algébrique car produit de 2 algébriques
 - ...
 - $L^* = \bigcup_{n \geq 0} L^n$ algébrique car union d'algébriques
- ▶ L est engendré par la grammaire algébrique :
 $G = \langle \{a, b\}, \{S, S'\}, S', R \rangle$ avec R :

$$\begin{array}{lcl} S' & \rightarrow & SS' \\ S & \rightarrow & aSb \end{array} \quad \begin{array}{l} \epsilon \\ \epsilon \end{array}$$

Intersection de langages algébriques

Soit le langage algébrique L sur l'alphabet Σ ,

Intersection :

- ▶ $L_1 \cap L_2 = \{u \in \Sigma^* \mid u \in L_1 \text{ et } u \in L_2\}$
- ▶ l'intersection de 2 langages algébriques n'est pas toujours algébrique

Intersection de langages algébriques

Un exemple de "conservation" du type algébrique :

- $L = \{u \in \{a, b\}^* \mid u = a^n b^p; p > n \geq 0\}$
 L est algébrique, engendré par la grammaire algébrique :
 $G = \langle \{a, b\}, \{S, T\}, S, R \rangle$ avec R :

$$\begin{array}{lcl} S & \rightarrow & aSb \\ T & \rightarrow & bT \end{array} \quad \left| \quad \begin{array}{l} T \\ b \end{array} \right.$$

- $L = L_1 \cap L_2$ avec :
 - $L_1 = \{u \in \{a, b\}^* \mid u = a^n b^p; p \geq n \geq 0\}$
 - et $L_2 = \{u \in \{a, b\}^* \mid u = a^n b^p; p \geq 0, n \geq 0, n \neq p\}$
 - $L_1 = \{a^n b^n\} \{b^q\}$ produits d'algébriques
 - $L_2 = \{a^n b^p \mid p < n\} \cup \{a^n b^p \mid p > n\}$ même raisonnement que pour L_1
- L est donc algébrique et intersection de 2 langages algébriques

Intersection de langages algébriques

Un exemple de non "conservation" du type algébrique :

- ▶ $L_1 = \{u \in \{a, b\}^* \mid u = a^n b^p c^n; p \geq 0, n \geq 0\}$
 L_1 est algébrique
- ▶ $L_2 = \{u \in \{a, b\}^* \mid u = a^n b^p c^p; p \geq 0, n \geq 0\}$
 L_2 est algébrique
- ▶ $L_1 \cap L_2 = \{u \in \{a, b\}^* \mid u = a^n b^n c^n; n \geq 0\}$
 $L_1 \cap L_2$ n'est pas algébrique (il est contextuel)

- l'intersection ne conserve pas nécessairement le type algébrique

Complémentaire de langage algébrique

Soit le langage algébrique L sur l'alphabet Σ ,

Complémentaire :

- ▶ $\complement L = \{u \in \Sigma^* \mid u \notin L\}$
- ▶ le complémentaire d'un langage algébrique n'est pas toujours algébrique

Complémentaire de langage algébrique

Exemple :

- ▶ Soient L_1 et L_2 , 2 langages algébriques avec $L_1 \cap L_2$ non algébrique.
- ▶ 3 cas possibles :
 - 1 $\complement L_1$ et $\complement L_2$ sont algébriques :
 $\complement L_1 \cup \complement L_2 = \{u \in \Sigma^* \mid u \notin L_1 \text{ ou } u \notin L_2\}$ alg. car union de 2 alg.
 $\complement(\complement L_1 \cup \complement L_2) = \{u \in \Sigma^* \mid u \in L_1 \text{ et } u \in L_2\} = L_1 \cap L_2$ non alg. par hyp.
Exemple où le \complement d'un algébrique est non algébrique.
 - 2 $\complement L_1$ algébrique et $\complement L_2$ non algébrique :
 L_2 est algébrique et $\complement L_2$ non algébrique.
 - 3 $\complement L_1$ non algébrique et $\complement L_2$ algébrique :
 L_1 est algébrique et $\complement L_1$ non algébrique.

- ▶ **le complémentaire ne conserve pas nécessairement le type algébrique**

